

LAPORAN TUGAS UAS KECERDASAN BUATAN
IMPLEMENTASI CONVOLUTIONAL NEURAL NETWORK
(CNN) UNTUK KLASIFIKASI CITRA BUAH APEL DAN JERUK



Disusun Oleh:

Muhammad Fadhil Qutrunnada

235060307111061

DEPARTEMEN TEKNIK ELEKTRO
FAKULTAS TEKNIK
UNIVERSITAS BRAWIJAYA

2026

KATA PENGANTAR

Puji syukur kehadiran Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan laporan yang berjudul “Implementasi Convolutional Neural Network (CNN) untuk Klasifikasi Citra Buah Apel dan Jeruk” dengan baik.

Laporan ini disusun sebagai salah satu bentuk pemenuhan tugas mata kuliah yang berkaitan dengan penerapan Machine Learning dan Deep Learning dalam pengolahan citra digital. Dalam proses penyusunan laporan ini, penulis memperoleh banyak pengetahuan mengenai penerapan metode Convolutional Neural Network (CNN) untuk melakukan klasifikasi objek berdasarkan gambar.

Penulis menyadari bahwa laporan ini masih memiliki berbagai kekurangan. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun demi perbaikan di masa mendatang.

Akhir kata, penulis berharap laporan ini dapat memberikan manfaat bagi pembaca serta menambah wawasan mengenai penerapan Deep Learning dalam bidang klasifikasi citra.

Malang, 20 Juni 2026

Penulis

DAFTAR ISI

KATA PENGANTAR.....	i
DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	iii
DAFTAR TABEL.....	iv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian.....	3
1.4 Manfaat Penelitian.....	5
BAB II DESKRIPSI DAN KEISTIMEWAAN WAHANA.....	6
2.1 Konsep Rancangan.....	6
2.2 Arsitektur Sistem & Spesifikasi Sistem Elektronik.....	6
2.2.1 Arsitektur Sistem.....	6
2.2.2 Diagram Blok Komponen.....	8
2.2.3 Komponen Sistem Penerbangan dan Komputasi.....	10
2.2.4 Anti Collision System.....	14
2.2.5 Power.....	15
2.2.6 Dropping Mechanism.....	16
2.3 Airframe dan Manufaktur.....	16
2.4 Ilustrasi Teknik dan Dimensi.....	17
2.4.1 Ilustrasi Wahana.....	17
2.4.2 Dimensi Wahana.....	18
2.5 Keistimewaan Wahana.....	19
2.5.1 Keandalan Navigasi pada Berbagai Kondisi Lingkungan.....	19
2.5.2 Kemampuan Deteksi Lingkungan Secara Real-Time.....	20
2.5.3 Presisi Pengiriman Payload.....	20
2.5.4 Autonomous Mission Management.....	20
2.5.5 Keselamatan dan Keamanan Operasi Penerbangan.....	21
2.5.6 Analisis Kemampuan Penyelesaian Misi.....	21
BAB III PENUTUP.....	22
LAMPIRAN.....	24

DAFTAR GAMBAR

Gambar 1. Alur Program Misi KRTI.....	8
Gambar 2. Arsitektur Sistem.....	12
Gambar 3. Arsitektur Algoritma Sistem.....	12
Gambar 4. Diagram Blok Pixhawk.....	14
Gambar 5. Diagram Blok Jetson.....	15
Gambar 6. Perspektif Wahana.....	22
Gambar 7. Rekaan Wahana Tampak Depan.....	23
Gambar 8. Rekaan Wahana Tampak Samping.....	23
Gambar 9. Rekaan Wahana Beserta Dimensi (Dalam Satuan Milimeter).....	24

DAFTAR TABEL

Tabel 1. Komponen Sistem Penerbangan dan Komputasi.....	21
Tabel 2. Komponen Anti Collision System.....	25
Tabel 3. Komponen Power.....	27
Tabel 4. Komponen Dropping Mechanism.....	28
Tabel 5. Komponen Airframe dan Manufaktur.....	29

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi Artificial Intelligence (AI) telah membawa berbagai kemajuan dalam bidang komputasi, salah satunya pada pengolahan citra digital. AI memungkinkan komputer untuk melakukan tugas yang umumnya membutuhkan kecerdasan manusia, seperti mengenali pola, mengidentifikasi objek, dan mengambil keputusan berdasarkan data yang tersedia.

Salah satu cabang AI yang banyak digunakan dalam pengolahan data adalah Machine Learning. Namun, untuk permasalahan klasifikasi citra, metode Deep Learning menjadi salah satu pendekatan yang paling efektif karena mampu mempelajari karakteristik visual suatu objek secara otomatis. Salah satu algoritma Deep Learning yang banyak diterapkan pada bidang pengolahan citra adalah *Convolutional Neural Network* (CNN).

CNN merupakan arsitektur jaringan saraf tiruan yang dirancang khusus untuk mengolah data berbentuk citra. CNN memiliki kemampuan untuk mengekstraksi fitur-fitur penting dari gambar secara otomatis, sehingga dapat menghasilkan tingkat akurasi yang tinggi dalam proses klasifikasi objek.

Pada penelitian ini, metode CNN diterapkan untuk melakukan klasifikasi citra buah apel dan jeruk. Pemilihan kedua jenis buah tersebut didasarkan pada kemudahan dalam memperoleh dataset serta adanya perbedaan karakteristik visual yang cukup jelas, seperti warna, tekstur, dan bentuk. Proses pelatihan model dilakukan menggunakan dataset citra buah yang diolah melalui platform *Google Collab*.

Melalui penelitian ini, diharapkan dapat diperoleh pemahaman mengenai penerapan metode CNN dalam klasifikasi citra serta mengetahui tingkat akurasi model dalam membedakan buah apel dan jeruk. Selain itu, penelitian ini juga dapat menjadi dasar dalam pengembangan sistem pengenalan objek yang lebih kompleks pada berbagai bidang aplikasi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun model klasifikasi citra buah apel dan jeruk menggunakan metode CNN?
2. Bagaimana proses pelatihan dan pengujian model CNN menggunakan dataset citra buah apel dan jeruk?
3. Bagaimana performa model CNN dalam mengklasifikasikan citra buah apel dan jeruk berdasarkan hasil pengujian yang dilakukan?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, penelitian ini bertujuan untuk:

1. Membangun model klasifikasi citra buah apel dan jeruk menggunakan metode CNN.
2. Melakukan proses pelatihan dan pengujian model CNN menggunakan dataset citra buah apel dan jeruk.
3. Menganalisis performa model CNN dalam mengklasifikasikan citra buah apel dan jeruk berdasarkan hasil pengujian yang diperoleh.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat baik secara teoritis maupun praktis.

1.4.1 Manfaat Teoritis

1. Menambah pemahaman mengenai penerapan Deep Learning, khususnya metode CNN, dalam bidang pengolahan citra digital.
2. Menjadi referensi bagi mahasiswa atau peneliti yang ingin mempelajari implementasi CNN pada sistem klasifikasi objek berbasis citra.
3. Memberikan gambaran mengenai tahapan pengembangan model klasifikasi citra mulai dari pengumpulan data, pelatihan model, hingga proses evaluasi.

1.4.2 Manfaat Praktis

1. Memberikan pengalaman dalam penerapan teknologi *Deep Learning* untuk menyelesaikan permasalahan klasifikasi objek berdasarkan citra digital.
2. Menunjukkan kemampuan metode CNN dalam mengenali dan membedakan objek berdasarkan karakteristik visual yang terdapat pada gambar.
3. Menjadi dasar pengembangan sistem klasifikasi objek yang lebih kompleks dengan jumlah kategori dan dataset yang lebih beragam.
4. Meningkatkan keterampilan dalam penggunaan *Python*, *TensorFlow*, dan *Google Collab* sebagai sarana pengembangan model kecerdasan buatan.

BAB II

DASAR TEORI

2.1 *Artificial Intelligence*

Artificial Intelligence (AI) atau kecerdasan buatan adalah bidang dalam ilmu komputer yang bertujuan untuk menciptakan sistem yang dapat meniru kemampuan intelektual manusia. Teknologi ini memungkinkan komputer untuk melakukan berbagai aktivitas yang umumnya memerlukan pemikiran manusia, seperti belajar dari pengalaman, mengenali pola, mengambil keputusan, dan memecahkan permasalahan. Selain itu, AI juga banyak diterapkan dalam berbagai aplikasi, seperti pengenalan suara, pemrosesan bahasa alami, serta identifikasi objek pada citra digital.

Seiring dengan perkembangan teknologi, penerapan Artificial Intelligence semakin meluas di berbagai sektor kehidupan. Teknologi ini telah memberikan kontribusi yang besar dalam bidang kesehatan, pendidikan, industri, transportasi, hingga pertanian melalui peningkatan efisiensi dan akurasi dalam berbagai proses. Salah satu cabang AI yang berkembang dengan sangat cepat adalah Machine Learning, yaitu metode yang memungkinkan sistem komputer mempelajari pola dari data dan meningkatkan kemampuannya secara otomatis tanpa memerlukan pemrograman secara rinci untuk setiap tugas yang dilakukan.

2.2 *Machine Learning*

Machine Learning merupakan salah satu bidang dalam Artificial Intelligence yang berfokus pada pengembangan sistem yang mampu belajar dari data. Melalui proses pembelajaran tersebut, komputer dapat mengenali pola, menemukan hubungan antar data, serta menghasilkan prediksi atau keputusan secara otomatis. Berbeda dengan pemrograman konvensional, Machine Learning tidak mengandalkan aturan yang ditentukan secara rinci oleh programmer, melainkan memanfaatkan data sebagai sumber pembelajaran utama.

Penerapan Machine Learning saat ini telah digunakan dalam berbagai bidang dan aplikasi kehidupan sehari-hari. Beberapa contoh penerapannya meliputi sistem rekomendasi produk, penyaringan email spam, prediksi kondisi cuaca, teknologi pengenalan wajah, serta klasifikasi citra digital. Kemampuan Machine Learning dalam mengolah data dalam jumlah besar menjadikannya salah satu teknologi yang banyak dimanfaatkan untuk membantu proses pengambilan keputusan.

Berdasarkan metode pembelajarannya, Machine Learning dapat dikelompokkan menjadi tiga kategori utama, yaitu Supervised Learning, Unsupervised Learning, dan Reinforcement Learning. Setiap kategori memiliki karakteristik dan mekanisme pembelajaran yang berbeda sesuai dengan jenis data serta tujuan yang ingin dicapai. Pemilihan metode yang tepat sangat penting untuk memperoleh hasil prediksi atau klasifikasi yang optimal.

Pada penelitian ini digunakan metode Supervised Learning karena data yang digunakan telah memiliki label kelas yang jelas. Setiap citra pada dataset telah dikategorikan ke dalam kelas apel atau jeruk sehingga model dapat mempelajari hubungan antara karakteristik gambar dan label yang diberikan. Dengan adanya label tersebut, proses pelatihan model dapat dilakukan secara lebih terarah untuk menghasilkan tingkat akurasi klasifikasi yang baik.

2.3 Deep Learning

Deep Learning merupakan salah satu cabang dari Machine Learning yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan untuk memproses dan mempelajari data. Metode ini dirancang agar mampu mengenali pola yang kompleks melalui proses pembelajaran berulang dari sejumlah besar data. Dengan struktur jaringan yang mendalam, *Deep Learning* dapat menghasilkan model yang memiliki kemampuan prediksi dan klasifikasi yang lebih baik dibandingkan metode konvensional pada beberapa jenis permasalahan.

Salah satu keunggulan utama *Deep Learning* adalah kemampuannya dalam melakukan ekstraksi fitur secara otomatis tanpa memerlukan proses pemilihan fitur secara manual. Kemampuan tersebut memungkinkan sistem untuk mempelajari karakteristik penting dari data secara mandiri selama proses pelatihan berlangsung. Oleh karena itu, *Deep Learning* sangat efektif digunakan untuk mengolah data yang memiliki tingkat kompleksitas tinggi, seperti citra digital, suara, maupun teks.

Seiring dengan perkembangan teknologi komputasi, *Deep Learning* telah banyak diterapkan dalam berbagai bidang kehidupan. Beberapa contoh penerapannya antara lain pada sistem pengenalan wajah, kendaraan otonom, penerjemahan bahasa otomatis, deteksi objek, serta klasifikasi citra. Tingginya tingkat akurasi yang dapat dicapai menjadikan *Deep Learning* sebagai salah satu metode yang banyak digunakan dalam pengembangan sistem kecerdasan buatan modern.

Salah satu algoritma *Deep Learning* yang paling populer dalam bidang pengolahan citra adalah *Convolutional Neural Network* (CNN). Algoritma ini dirancang khusus untuk mengolah data berbentuk gambar dengan memanfaatkan proses konvolusi dalam mengekstraksi fitur-fitur visual. Kemampuan tersebut membuat CNN banyak digunakan pada berbagai tugas klasifikasi citra, termasuk dalam penelitian klasifikasi buah apel dan jeruk yang dilakukan pada penelitian ini.

2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan salah satu metode *Deep Learning* yang secara khusus dikembangkan untuk mengolah data berbentuk citra. CNN memiliki kemampuan untuk mempelajari dan mengenali berbagai karakteristik visual yang terdapat pada gambar secara otomatis tanpa memerlukan proses ekstraksi fitur secara manual. Kemampuan tersebut menjadikan CNN sebagai salah satu

algoritma yang banyak digunakan dalam berbagai aplikasi pengolahan citra, seperti pengenalan wajah, deteksi objek, dan klasifikasi gambar.

Arsitektur CNN tersusun atas beberapa lapisan yang bekerja secara berurutan untuk mengekstraksi fitur dan melakukan proses klasifikasi. Setiap lapisan memiliki fungsi yang berbeda dalam mengolah informasi dari citra masukan hingga menghasilkan prediksi kelas. Adapun lapisan utama yang digunakan dalam CNN meliputi *Convolution Layer*, *Pooling Layer*, *Flatten Layer*, dan *Dense Layer*.

2.4.1 Convolution Layer

Convolution Layer merupakan lapisan pertama yang berperan dalam proses ekstraksi fitur dari citra masukan. Pada lapisan ini, gambar diproses menggunakan sejumlah filter atau kernel yang bergerak di seluruh area citra untuk mendeteksi pola-pola tertentu. Hasil dari proses tersebut berupa *feature map* yang berisi informasi mengenai karakteristik visual seperti garis, tepi, bentuk, warna, maupun tekstur objek pada gambar.

2.4.2 Pooling Layer

Pooling Layer merupakan lapisan yang berfungsi untuk mengurangi ukuran dimensi *feature map* yang dihasilkan oleh *Convolution Layer*. Proses ini dilakukan dengan mengambil nilai-nilai tertentu dari setiap area *feature map* sehingga jumlah data yang diproses menjadi lebih kecil. Selain meningkatkan efisiensi komputasi, penggunaan *Pooling Layer* juga membantu mengurangi risiko *overfitting* dan meningkatkan kemampuan model dalam mengenali objek pada berbagai kondisi.

2.4.3 Flatten Layer

Flatten Layer berfungsi untuk mengubah data hasil proses konvolusi dan pooling yang masih berbentuk matriks dua dimensi menjadi vektor satu dimensi. Proses ini diperlukan agar data dapat diteruskan ke lapisan klasifikasi pada tahap berikutnya. Dengan demikian, seluruh fitur yang telah diekstraksi dapat diolah lebih lanjut oleh jaringan saraf tiruan untuk menghasilkan prediksi.

2.4.4 Dense Layer

Dense Layer atau *Fully Connected Layer* merupakan lapisan akhir yang bertugas melakukan proses klasifikasi berdasarkan fitur-fitur yang telah diperoleh dari lapisan sebelumnya. Pada lapisan ini, setiap neuron terhubung dengan seluruh neuron pada lapisan sebelumnya sehingga informasi dapat diproses secara menyeluruh. Dalam penelitian ini, *Dense Layer* digunakan untuk menentukan kategori citra yang diuji, yaitu apakah termasuk ke dalam kelas apel atau kelas jeruk.

2.5 TensorFlow dan Keras

TensorFlow merupakan salah satu *framework open-source* yang banyak digunakan dalam pengembangan *Machine Learning* dan *Deep Learning*. *Framework* ini dikembangkan oleh Google untuk membantu proses pembuatan, pelatihan, dan penerapan model kecerdasan buatan secara lebih efisien. *TensorFlow* menyediakan berbagai pustaka dan fitur yang mendukung pengolahan data, pembangunan model, serta optimasi proses pembelajaran pada jaringan saraf tiruan.

Keras merupakan *Application Programming Interface* (API) tingkat tinggi yang terintegrasi dengan *TensorFlow* dan dirancang untuk mempermudah pengembangan model *Deep Learning*. Keras menyediakan berbagai fungsi dan komponen yang memungkinkan pengguna membangun arsitektur jaringan saraf dengan sintaks yang lebih sederhana dan mudah dipahami. Dengan demikian, proses perancangan, pelatihan, dan pengujian model dapat dilakukan secara lebih cepat dibandingkan menggunakan *TensorFlow* tingkat rendah secara langsung.

Kombinasi *TensorFlow* dan Keras banyak digunakan dalam berbagai penelitian maupun pengembangan aplikasi berbasis kecerdasan buatan karena menawarkan fleksibilitas, kemudahan penggunaan, dan performa yang baik. Kedua *framework* tersebut mendukung berbagai jenis arsitektur jaringan saraf, termasuk CNN yang banyak digunakan dalam pengolahan citra digital. Selain itu, *TensorFlow* dan Keras juga menyediakan berbagai fitur visualisasi dan evaluasi yang membantu pengguna dalam menganalisis kinerja model yang dibangun.

Pada penelitian ini, *TensorFlow* dan Keras digunakan sebagai alat utama untuk membangun, melatih, dan mengevaluasi model CNN. Proses pelatihan dilakukan menggunakan dataset citra buah apel dan jeruk yang telah dipersiapkan sebelumnya. Melalui penggunaan *TensorFlow* dan Keras, model CNN dapat dikembangkan dengan lebih mudah sehingga mampu melakukan klasifikasi citra buah secara efektif dan menghasilkan tingkat akurasi yang baik.

2.6 Google Collab

Google Collab atau *Google Collaboratory* merupakan platform berbasis cloud yang disediakan oleh Google untuk menjalankan program Python secara langsung melalui web browser. Platform ini memungkinkan pengguna untuk menulis, menjalankan, dan mengelola kode tanpa harus melakukan instalasi perangkat lunak atau konfigurasi lingkungan pemrograman pada perangkat lokal. Dengan kemudahan tersebut, *Google Collab* menjadi salah satu platform yang banyak digunakan dalam pengembangan proyek *Machine Learning* dan *Deep Learning*.

Google Collab mendukung berbagai pustaka dan *framework* yang umum digunakan dalam pengolahan data serta kecerdasan buatan, seperti *TensorFlow*, Keras, NumPy, Pandas, dan Matplotlib. Selain itu, pengguna dapat mengakses berbagai sumber daya komputasi yang disediakan oleh Google untuk mempercepat

proses pelatihan model. Dukungan terhadap berbagai pustaka tersebut menjadikan *Google Collab* sebagai lingkungan pengembangan yang fleksibel dan mudah digunakan.

Salah satu keunggulan utama *Google Collab* adalah tersedianya fasilitas *Graphics Processing Unit* (GPU) dan *Tensor Processing Unit* (TPU) yang dapat digunakan secara gratis untuk mempercepat proses komputasi. Selain itu, *Google Collab* juga terintegrasi dengan *Google Drive* sehingga memudahkan pengguna dalam menyimpan, mengakses, dan mengelola dataset maupun file proyek. Kemudahan akses yang dapat dilakukan dari berbagai perangkat selama terhubung ke internet menjadi nilai tambah dari platform ini.

Pada penelitian ini, *Google Collab* digunakan sebagai lingkungan pengembangan untuk membangun dan melatih model CNN. Seluruh proses pengolahan dataset, pelatihan model, pengujian, serta evaluasi hasil klasifikasi dilakukan menggunakan platform tersebut. Pemanfaatan *Google Collab* membantu mempercepat proses penelitian sekaligus mempermudah pengelolaan data dan kode program yang digunakan.

2.7 Pengolahan Citra Digital

Pengolahan citra digital merupakan suatu proses yang dilakukan untuk memperoleh, memperbaiki, menganalisis, atau mengekstraksi informasi dari sebuah gambar menggunakan bantuan komputer. Teknik ini memungkinkan citra yang awalnya hanya berupa kumpulan piksel dapat diolah menjadi informasi yang lebih bermakna sesuai dengan tujuan tertentu. Pengolahan citra digital banyak diterapkan dalam berbagai bidang, seperti pengenalan wajah, deteksi objek, sistem keamanan, serta analisis medis.

Dalam bidang *Machine Learning* dan *Deep Learning*, citra digital berperan sebagai data masukan yang digunakan untuk melatih model dalam mengenali pola dan karakteristik suatu objek. Setiap gambar tersusun atas sejumlah piksel yang menyimpan informasi warna dan intensitas cahaya. Melalui proses pembelajaran, model dapat mempelajari hubungan antara pola visual yang terdapat pada citra dengan kategori atau kelas yang telah ditentukan.

Tahapan pengolahan citra digital umumnya meliputi akuisisi citra, prapemrosesan (*preprocessing*), ekstraksi fitur, dan klasifikasi. Prapemrosesan dilakukan untuk meningkatkan kualitas citra agar lebih mudah dianalisis oleh sistem. Selanjutnya, fitur-fitur penting dari citra akan dipelajari oleh model untuk menghasilkan proses klasifikasi yang lebih akurat.

Pada penelitian ini, citra digital yang digunakan berupa gambar buah apel dan jeruk yang diperoleh dari dataset yang telah disiapkan sebelumnya. Citra tersebut digunakan sebagai data pelatihan dan data validasi dalam proses pembentukan model CNN. Melalui proses pembelajaran terhadap dataset tersebut, model diharapkan

mampu mengenali perbedaan karakteristik visual antara buah apel dan jeruk sehingga dapat melakukan klasifikasi dengan tingkat akurasi yang baik.

BAB III METODOLOGI PENELITIAN

3.1 Metode Penelitian

Penelitian ini menggunakan metode eksperimen dengan menerapkan algoritma CNN untuk melakukan klasifikasi citra buah apel dan jeruk. Metode eksperimen dipilih karena memungkinkan peneliti untuk membangun, melatih, dan menguji model secara langsung menggunakan dataset yang telah disiapkan. Melalui metode ini, performa model dapat diamati dan dianalisis berdasarkan hasil klasifikasi yang diperoleh selama proses pengujian.

Penelitian dilakukan menggunakan bahasa pemrograman Python dengan bantuan *framework TensorFlow* dan Keras yang dijalankan pada platform *Google Collab*. Dataset yang digunakan terdiri dari citra buah apel dan jeruk yang telah dikelompokkan berdasarkan kelas masing-masing. Hasil dari penelitian ini berupa model CNN yang mampu mengidentifikasi dan mengklasifikasikan gambar ke dalam kategori apel atau jeruk.

Untuk mencapai tujuan penelitian, proses pengembangan model dilakukan melalui beberapa tahapan, yaitu *preprocessing data*, *training model*, *testing model*, evaluasi model, dan demo sistem. Setiap tahapan memiliki fungsi yang berbeda namun saling berkaitan dalam menghasilkan model klasifikasi yang optimal.

Tabel 1. Metode Penelitian

No	Tahapan	Deskripsi
1	<i>Preprocessing</i>	Persiapan dan pengolahan data sebelum pelatihan
2	<i>Training</i>	Pelatihan model CNN menggunakan dataset
3	<i>Testing</i>	Pengujian model menggunakan gambar masukan
4	Evaluasi	Analisis performa model berdasarkan hasil klasifikasi
5	Demo	Demonstrasi penggunaan model yang telah dilatih

Penelitian dilakukan secara bertahap mulai dari pengolahan data hingga demonstrasi sistem. Setiap tahapan dirancang untuk memastikan model dapat mempelajari karakteristik citra buah dengan baik dan menghasilkan prediksi yang sesuai. Hasil dari setiap tahapan akan digunakan sebagai dasar dalam pembahasan pada bab selanjutnya.

3.2 Preprocessing Data

Preprocessing merupakan tahap awal yang dilakukan sebelum proses pelatihan model CNN. Tahap ini bertujuan untuk mempersiapkan dataset agar memiliki format yang seragam dan sesuai dengan kebutuhan model. Data yang digunakan dalam penelitian ini berupa citra buah apel dan jeruk yang telah dikelompokkan ke dalam folder berdasarkan kelasnya.

Pada tahap preprocessing, seluruh gambar diubah ukurannya menjadi 150×150 piksel. Proses ini dilakukan untuk menyamakan dimensi setiap gambar sehingga dapat diproses oleh model secara konsisten. Selain itu, ukuran gambar yang seragam juga membantu mengurangi beban komputasi selama proses pelatihan berlangsung.

Tahap selanjutnya adalah normalisasi data, yaitu mengubah nilai piksel gambar ke dalam rentang 0 hingga 1. Normalisasi dilakukan agar proses pembelajaran model menjadi lebih stabil dan cepat. Setelah itu, data dibagi menjadi data pelatihan dan data validasi yang digunakan selama proses training model.

Tabel 2. Preprocessing Data

No	Proses	Tujuan
1	Pengumpulan Dataset	Menyiapkan data citra apel dan jeruk
2	Resize Gambar	Menyamakan ukuran gambar menjadi 150×150 piksel
3	Normalisasi	Menyesuaikan nilai piksel ke rentang 0–1
4	Pelabelan Data	Memberikan label sesuai kategori buah
5	Pembagian Data	Membagi data menjadi data pelatihan dan validasi

Preprocessing dilakukan untuk memastikan kualitas data yang digunakan selama pelatihan model. Data yang telah melalui tahap *preprocessing* akan lebih mudah dipelajari oleh jaringan CNN sehingga dapat meningkatkan performa klasifikasi. Tahap ini menjadi salah satu faktor penting dalam keberhasilan pembangunan model.

3.3 Training Model

Training merupakan proses pembelajaran model CNN menggunakan dataset yang telah dipersiapkan sebelumnya. Pada tahap ini, model mempelajari pola dan karakteristik visual yang membedakan buah apel dan jeruk. Proses pembelajaran dilakukan secara berulang melalui sejumlah epoch hingga model mampu menghasilkan prediksi yang lebih akurat.

Model CNN yang digunakan terdiri dari beberapa lapisan seperti *Convolution Layer*, *Pooling Layer*, *Flatten Layer*, dan *Dense Layer*. Setiap lapisan memiliki fungsi masing-masing dalam mengekstraksi fitur serta melakukan klasifikasi terhadap gambar yang diberikan. Melalui kombinasi lapisan tersebut, model dapat mengenali karakteristik seperti bentuk, warna, dan tekstur objek pada citra.

Pelatihan model dilakukan menggunakan *TensorFlow* dan Keras dengan beberapa parameter yang telah ditentukan sebelumnya. Parameter tersebut digunakan untuk mengatur proses pembelajaran sehingga model dapat mencapai performa yang optimal.

Tabel 3. Parameter Training Model

Parameter	Nilai
Image Size	150 × 150 piksel
Epoch	10
Batch Size	32
Optimizer	Adam
Loss Function	Binary Crossentropy
Activation Function	ReLU dan Sigmoid

Proses *training* dilakukan selama 10 epoch menggunakan *optimizer* Adam. *Optimizer* tersebut dipilih karena mampu mempercepat proses pembelajaran dan menghasilkan konvergensi yang lebih baik. Hasil dari tahap training berupa model CNN yang siap digunakan untuk proses pengujian.

3.4 Testing Model

Testing merupakan tahap pengujian model yang telah dilatih untuk mengetahui kemampuan klasifikasinya terhadap data masukan. Pada tahap ini, model diberikan gambar buah yang kemudian diproses untuk menghasilkan prediksi kelas. Hasil prediksi yang diberikan berupa kategori apel atau jeruk sesuai dengan objek yang dikenali.

Pengujian dilakukan menggunakan gambar yang tidak digunakan secara langsung dalam proses pelatihan. Tujuannya adalah untuk mengetahui kemampuan model dalam mengenali objek pada kondisi yang berbeda. Semakin baik hasil

pengujian yang diperoleh, maka semakin baik pula kemampuan model dalam melakukan generalisasi terhadap data baru.

Berdasarkan hasil testing, model mampu memberikan prediksi sesuai dengan kategori objek yang terdapat pada gambar. Hasil ini menunjukkan bahwa model telah berhasil mempelajari karakteristik visual yang membedakan kedua jenis buah tersebut. Tahap testing menjadi dasar untuk melakukan evaluasi terhadap performa model.

3.5 Evaluasi Model

Evaluasi dilakukan untuk mengukur tingkat keberhasilan model CNN dalam melakukan klasifikasi citra buah. Pada penelitian ini, evaluasi dilakukan dengan memperhatikan nilai accuracy dan loss yang diperoleh selama proses pelatihan maupun pengujian. Kedua parameter tersebut digunakan sebagai indikator utama dalam menilai kualitas model yang dihasilkan.

Nilai accuracy menunjukkan persentase prediksi yang berhasil dilakukan dengan benar oleh model. Sementara itu, nilai loss menunjukkan tingkat kesalahan model selama proses pembelajaran. Model yang baik umumnya memiliki nilai accuracy yang tinggi dan nilai loss yang rendah.

Tabel 4. Parameter Evaluasi Model

Parameter	Keterangan
Accuracy	Tingkat ketepatan prediksi model
Loss	Tingkat kesalahan model selama pelatihan

Melalui proses evaluasi, dapat diketahui apakah model telah mampu memenuhi tujuan penelitian yang telah ditetapkan. Hasil evaluasi juga digunakan sebagai dasar untuk melakukan analisis terhadap kelebihan dan keterbatasan model yang dibangun.

3.6 Demo Sistem

Demo sistem dilakukan untuk menunjukkan cara kerja model CNN yang telah berhasil dilatih. Pada tahap ini, pengguna memasukkan gambar buah sebagai data masukan, kemudian model akan memproses gambar tersebut dan menghasilkan prediksi sesuai dengan kategori yang dikenali. Proses ini menunjukkan bagaimana model dapat digunakan secara langsung dalam melakukan klasifikasi citra.

Demo dilakukan menggunakan gambar buah apel dan jeruk yang dimasukkan ke dalam sistem melalui program yang telah dibuat. Model akan melakukan ekstraksi fitur secara otomatis dan menentukan kelas objek berdasarkan hasil pembelajaran

sebelumnya. Hasil prediksi kemudian ditampilkan kepada pengguna sebagai keluaran sistem.

Tabel 5. Alur Demo Sistem


Tahapan	Keterangan
Input	Pengguna memilih gambar buah
Proses	Model CNN melakukan klasifikasi
Output	Sistem menampilkan hasil prediksi

Berdasarkan proses demo yang dilakukan, model mampu memberikan hasil klasifikasi secara otomatis sesuai dengan gambar yang diberikan. Hal ini menunjukkan bahwa sistem yang dibangun telah berhasil menjalankan fungsi utamanya sebagai pengklasifikasi citra buah apel dan jeruk. Tahap demo juga menjadi bukti bahwa model dapat digunakan dalam implementasi nyata sesuai tujuan penelitian.

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil *Preprocessing* Data

Pada tahap *preprocessing*, dataset buah apel dan jeruk dipersiapkan sebelum digunakan dalam proses pelatihan model CNN. *Dataset* disusun ke dalam folder berdasarkan kelas masing-masing sehingga sistem dapat membaca label data secara otomatis. Selain itu, seluruh gambar diubah ukurannya menjadi 150×150 piksel dan dilakukan normalisasi agar proses pelatihan berjalan lebih optimal.



```
[ ] from google.colab import files
    uploaded = files.upload()

Choose Files Dataset.zip
Dataset.zip(application/x-zip-compressed) - 87268549 bytes, last modified: 6/20/2026 -
100% done
Saving Dataset.zip to Dataset.zip

[ ] import zipfile

    with zipfile.ZipFile('Dataset.zip', 'r') as zip_ref:
        zip_ref.extractall()

[ ] import os

    print(os.listdir("Dataset"))

['Apel', 'Jeruk']
```

Gambar 1. Hasil *Preprocessing* Data

Berdasarkan Gambar 1, dataset berhasil diunggah ke *Google Collab* menggunakan fungsi `files.upload()` dari library *Google Collab*. Setelah proses unggah selesai, file dataset yang masih dalam bentuk terkompresi diekstrak menggunakan library *zipfile* sehingga seluruh gambar yang terdapat di dalamnya dapat diakses oleh sistem. Proses ekstraksi dilakukan untuk memisahkan file gambar ke dalam struktur folder yang dapat dibaca oleh program pelatihan CNN.

Selanjutnya dilakukan pengecekan isi folder *dataset* menggunakan library *os*. Hasil pengecekan menunjukkan bahwa sistem berhasil mengenali dua folder utama, yaitu folder *Apel* dan folder *Jeruk*. Kedua folder tersebut berfungsi sebagai label kelas yang akan digunakan selama proses pelatihan model untuk membedakan gambar buah apel dan jeruk.

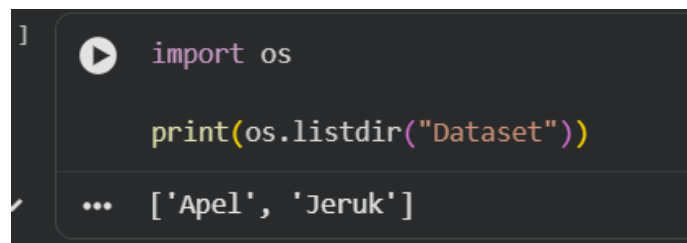
Keberhasilan proses pembacaan folder menunjukkan bahwa dataset telah tersusun dengan baik dan siap digunakan pada tahap berikutnya. Struktur dataset yang terorganisir sangat penting karena TensorFlow dan Keras memanfaatkan nama folder sebagai label kelas secara otomatis. Dengan demikian, sistem dapat mengidentifikasi setiap gambar berdasarkan kategori yang telah ditentukan tanpa perlu melakukan pelabelan secara manual.

Tahap *preprocessing* ini menjadi langkah penting dalam penelitian karena kualitas dan struktur dataset akan memengaruhi proses pembelajaran model CNN. Apabila terjadi kesalahan pada tahap pengunggahan, ekstraksi, atau pembacaan folder *dataset*, maka proses pelatihan model tidak dapat dilakukan dengan baik. Oleh karena itu, keberhasilan tahap *preprocessing* menjadi indikator bahwa data telah siap digunakan untuk proses training model.

4.2 Pembagian Dataset

Dataset pada penelitian ini terdiri dari dua kelas, yaitu apel dan jeruk yang masing-masing disimpan dalam bentuk folder gambar sesuai kategorinya. Struktur dataset ditemukan dalam bentuk folder bertingkat (*nested folder*), sehingga akses data dilakukan melalui direktori tambahan sesuai lokasi penyimpanan. Setiap folder berisi kumpulan gambar yang akan digunakan sebagai data dalam proses pelatihan dan pengujian model.

Selanjutnya, dataset dibagi menjadi dua bagian utama, yaitu data *training* dan data *testing*. Pembagian dilakukan dengan perbandingan 80% untuk data training dan 20% untuk data testing. Data training digunakan untuk melatih model agar mampu mengenali pola pada gambar apel dan jeruk, sedangkan data testing digunakan untuk menguji kemampuan model dalam melakukan klasifikasi terhadap data baru.



```
] ▶ import os  
  
    print(os.listdir("Dataset"))  
  
✓ ... ['Apel', 'Jeruk']
```

Gambar 2. Sampel Data

Pembagian dataset ini bertujuan untuk memastikan model dapat belajar secara optimal dari data yang tersedia. Selain itu, pengujian menggunakan data testing dilakukan untuk mengevaluasi kinerja model secara objektif. Dengan adanya pembagian ini, diharapkan model mampu menghasilkan tingkat akurasi yang baik dalam mengklasifikasikan buah apel dan jeruk.

4.3 Hasil *Training* Model CNN

Setelah proses preprocessing selesai dilakukan, tahap berikutnya adalah pelatihan *training* model CNN. Pada tahap ini, model dilatih menggunakan dataset buah apel dan jeruk yang telah dipersiapkan sebelumnya. Tujuan dari proses training adalah agar model dapat mempelajari karakteristik visual yang membedakan kedua jenis buah berdasarkan pola yang terdapat pada gambar.

Model CNN dibangun menggunakan framework *TensorFlow* dan Keras yang dijalankan pada platform *Google Collab*. Arsitektur model terdiri dari beberapa lapisan, yaitu *Convolution Layer*, *Max Pooling Layer*, *Flatten Layer*, dan *Dense Layer*. Setiap lapisan memiliki fungsi yang berbeda dalam mengekstraksi fitur serta melakukan klasifikasi terhadap citra yang diberikan.

```

import tensorflow as tf
from tensorflow.keras import layers
from tensorflow.keras.models import Sequential

IMG_SIZE = (100,100)
BATCH_SIZE = 32

train_ds = tf.keras.utils.image_dataset_from_directory(
    "Dataset",
    validation_split=0.2,
    subset="training",
    seed=123,
    image_size=IMG_SIZE,
    batch_size=BATCH_SIZE
)

val_ds = tf.keras.utils.image_dataset_from_directory(
    "Dataset",
    validation_split=0.2,
    subset="validation",
    seed=123,
    image_size=IMG_SIZE,
    batch_size=BATCH_SIZE
)

model = Sequential([
    layers.Rescaling(1./255),

    layers.Conv2D(16,3,activation='relu'),
    layers.MaxPooling2D(),

```

Gambar 3. Arsitektur Model CNN

Berdasarkan Gambar 4.6, model CNN terdiri dari beberapa lapisan yang bekerja secara berurutan untuk memproses data citra. Lapisan konvolusi berfungsi mengekstraksi fitur-fitur penting seperti bentuk, warna, dan tekstur objek. Selanjutnya, lapisan *pooling* digunakan untuk mengurangi dimensi data sehingga proses komputasi menjadi lebih efisien tanpa menghilangkan informasi penting yang terdapat pada gambar.

```

Found 1206 files belonging to 2 classes.
Using 965 files for training.
Found 1206 files belonging to 2 classes.
Using 241 files for validation.
Epoch 1/10
31/31 ----- 14s 352ms/step - accuracy: 0.8456 - loss: 0.3574 - val_accuracy: 0.9544 - val_loss: 0.1331
Epoch 2/10
31/31 ----- 12s 370ms/step - accuracy: 0.9679 - loss: 0.0957 - val_accuracy: 0.9502 - val_loss: 0.1648
Epoch 3/10
31/31 ----- 19s 321ms/step - accuracy: 0.9907 - loss: 0.0320 - val_accuracy: 0.9876 - val_loss: 0.0455
Epoch 4/10
31/31 ----- 11s 328ms/step - accuracy: 0.9979 - loss: 0.0112 - val_accuracy: 0.9959 - val_loss: 0.0276
Epoch 5/10
31/31 ----- 21s 350ms/step - accuracy: 0.9979 - loss: 0.0066 - val_accuracy: 0.9917 - val_loss: 0.0444
Epoch 6/10
31/31 ----- 11s 361ms/step - accuracy: 1.0000 - loss: 0.0012 - val_accuracy: 0.9917 - val_loss: 0.0473
Epoch 7/10
31/31 ----- 11s 351ms/step - accuracy: 1.0000 - loss: 0.0017 - val_accuracy: 0.9959 - val_loss: 0.0187
Epoch 8/10
31/31 ----- 20s 341ms/step - accuracy: 1.0000 - loss: 0.0015 - val_accuracy: 0.9917 - val_loss: 0.0481
Epoch 9/10
31/31 ----- 11s 346ms/step - accuracy: 1.0000 - loss: 3.1482e-04 - val_accuracy: 0.9917 - val_loss: 0.0406
Epoch 10/10
31/31 ----- 20s 336ms/step - accuracy: 1.0000 - loss: 1.7099e-04 - val_accuracy: 0.9917 - val_loss: 0.0370

```

Gambar 4. Hasil Training Model CNN

Berdasarkan Gambar 3, proses pelatihan model CNN dilakukan menggunakan dataset yang terdiri dari 1.206 citra yang terbagi ke dalam dua kelas, yaitu apel dan jeruk. Dari total dataset tersebut, sebanyak 965 citra digunakan sebagai data pelatihan (*training data*) dan 241 citra digunakan sebagai data validasi (*validation data*). Pembagian data ini bertujuan agar model

dapat dilatih menggunakan sebagian besar data sekaligus diuji kemampuannya menggunakan data yang tidak terlibat secara langsung dalam proses pembelajaran.

Pada epoch pertama, model memperoleh nilai *training accuracy* sebesar 84,56% dengan nilai *loss* sebesar 0,3574, sedangkan *validation accuracy* mencapai 95,44% dengan nilai *validation loss* sebesar 0,1331. Hasil ini menunjukkan bahwa sejak awal proses pelatihan model telah mampu mengenali sebagian besar pola yang terdapat pada dataset. Meskipun demikian, nilai *loss* yang masih relatif tinggi menunjukkan bahwa model masih memerlukan proses pembelajaran lebih lanjut untuk meningkatkan performanya.

Seiring bertambahnya jumlah epoch, performa model mengalami peningkatan yang signifikan. Pada epoch kedua hingga epoch kelima, nilai *accuracy* terus meningkat dari 96,79% menjadi 99,79%, sementara nilai *loss* mengalami penurunan secara bertahap. Kondisi ini menunjukkan bahwa model semakin mampu mempelajari karakteristik visual yang membedakan buah apel dan jeruk serta mengurangi kesalahan prediksi selama proses pelatihan.


Pada epoch keenam hingga epoch kesepuluh, model berhasil mencapai nilai *training accuracy* sebesar 100%. Selain itu, nilai *loss* terus menurun hingga mencapai 0,00017099 pada epoch terakhir. Hasil tersebut menunjukkan bahwa model telah mampu mempelajari pola-pola yang terdapat pada data pelatihan dengan sangat baik sehingga hampir tidak ditemukan kesalahan selama proses klasifikasi pada data training. Selain memperhatikan data pelatihan, performa model juga dapat dilihat dari data validasi. Berdasarkan hasil yang diperoleh, nilai *validation accuracy* berada pada kisaran 99,17% hingga 99,59% selama beberapa epoch terakhir.

Nilai tersebut menunjukkan bahwa model tidak hanya bekerja dengan baik pada data pelatihan, tetapi juga memiliki kemampuan yang sangat baik dalam mengenali data yang belum pernah dilihat sebelumnya. Secara keseluruhan, hasil pelatihan menunjukkan bahwa metode Convolutional Neural Network (CNN) mampu melakukan klasifikasi citra buah apel dan jeruk dengan tingkat akurasi yang sangat tinggi. Nilai *training accuracy* sebesar 100% dan *validation accuracy* sebesar 99,17% pada akhir pelatihan menunjukkan bahwa model telah berhasil mempelajari karakteristik visual dari kedua kelas buah yang digunakan dalam penelitian ini. Dengan hasil tersebut, model dinilai layak untuk digunakan pada tahap pengujian (*testing*).

4.4 Testing Model

Pada tahap pengujian, model yang telah dilatih digunakan untuk mengklasifikasikan gambar buah yang belum pernah digunakan selama proses pelatihan. Pengujian dilakukan dengan memasukkan gambar buah apel ke dalam sistem untuk mengetahui kemampuan model dalam mengenali objek berdasarkan pola yang telah dipelajari sebelumnya. Proses ini bertujuan untuk mengevaluasi kemampuan model dalam melakukan prediksi terhadap data baru.

Berdasarkan hasil pengujian yang ditunjukkan pada Gambar 4.4, model berhasil mengidentifikasi gambar yang diuji sebagai buah apel. Hasil prediksi menunjukkan label "Apel" dengan tingkat keyakinan sebesar 97,62%, sedangkan probabilitas untuk kelas jeruk hanya sebesar 2,38%. Nilai tersebut menunjukkan bahwa model memiliki tingkat kepercayaan yang tinggi terhadap hasil klasifikasi yang diberikan.



Gambar 5. Hasil Prediksi

Hasil pengujian ini membuktikan bahwa model mampu mengenali karakteristik visual buah apel dengan baik berdasarkan data yang telah dipelajari selama proses training. Tingginya nilai keyakinan yang diperoleh menunjukkan bahwa model memiliki kemampuan yang cukup baik dalam membedakan antara kelas apel dan jeruk. Dengan demikian, model dapat digunakan untuk melakukan klasifikasi gambar buah secara otomatis sesuai dengan kategori yang telah ditentukan.


4.5 Evaluasi Model

Pada tahap evaluasi, performa model diukur menggunakan grafik akurasi pelatihan (*training accuracy*) dan akurasi validasi (*validation accuracy*). Evaluasi ini bertujuan untuk mengetahui kemampuan model dalam mempelajari pola dari data training serta kemampuannya dalam melakukan prediksi pada data yang belum pernah dilihat sebelumnya. Hasil evaluasi ditampilkan pada Gambar 6 yang menunjukkan perkembangan nilai akurasi selama proses pelatihan berlangsung.

Berdasarkan Gambar 6, nilai akurasi training mengalami peningkatan yang signifikan dari sekitar 86% pada epoch pertama hingga mencapai 100% pada epoch keempat. Sementara itu, akurasi validasi juga menunjukkan peningkatan yang stabil dari sekitar 95% hingga mencapai 99,7%. Peningkatan tersebut menunjukkan bahwa model mampu mempelajari karakteristik data dengan baik dan menghasilkan performa yang semakin baik pada setiap epoch.

Selain itu, jarak antara kurva akurasi training dan validasi relatif kecil, yang menandakan bahwa model tidak mengalami overfitting yang signifikan. Hal ini menunjukkan bahwa model tidak hanya mampu menghafal data training, tetapi juga memiliki kemampuan yang baik dalam melakukan generalisasi terhadap data baru. Dengan demikian, model yang dibangun dapat dikatakan memiliki tingkat performa yang sangat baik untuk tugas klasifikasi buah apel dan jeruk.

Berdasarkan hasil evaluasi yang diperoleh, model berhasil mencapai tingkat akurasi yang sangat tinggi pada data training maupun data validasi. Hasil tersebut menunjukkan bahwa model mampu melakukan klasifikasi buah apel dan jeruk dengan baik serta memiliki kemampuan prediksi yang akurat terhadap data yang diuji.



Gambar 6. Grafik Akurasi Training dan Validation Model Klasifikasi Buah Apel dan

Berdasarkan hasil evaluasi yang diperoleh, model berhasil mencapai tingkat akurasi yang sangat tinggi pada data training maupun data validasi. Hasil tersebut menunjukkan bahwa model mampu melakukan klasifikasi buah apel dan jeruk dengan baik serta memiliki kemampuan prediksi yang akurat terhadap data yang diuji.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, sistem klasifikasi buah apel dan jeruk berhasil dibangun menggunakan metode Convolutional Neural Network (CNN). Model dilatih menggunakan dataset citra buah yang telah melalui tahap preprocessing berupa resize dan normalisasi gambar. Hasil pelatihan menunjukkan bahwa model mampu membedakan buah apel dan jeruk dengan tingkat akurasi yang baik.

Proses pengembangan sistem dilakukan menggunakan *TensorFlow* dan *Google Collab* sebagai lingkungan pemrograman. Penggunaan platform tersebut memudahkan proses pelatihan model karena menyediakan berbagai pustaka yang mendukung implementasi Deep Learning. Selain itu, proses pengujian menunjukkan bahwa model dapat melakukan prediksi terhadap gambar baru dengan cukup baik.

Penelitian ini membuktikan bahwa metode CNN dapat diterapkan untuk menyelesaikan permasalahan klasifikasi citra sederhana. Model mampu mempelajari karakteristik visual dari masing-masing kelas berdasarkan data pelatihan yang diberikan. Dengan demikian, tujuan penelitian untuk membangun sistem klasifikasi buah apel dan jeruk telah berhasil dicapai.

5.2 Saran

Pada penelitian selanjutnya, jumlah dataset dapat ditingkatkan agar model memperoleh lebih banyak variasi data. Semakin banyak data yang digunakan, semakin baik kemampuan model dalam mengenali objek baru. Hal tersebut juga dapat membantu meningkatkan akurasi klasifikasi.

Pengembangan berikutnya dapat dilakukan dengan menambahkan lebih banyak jenis buah sebagai kelas klasifikasi. Penambahan kelas akan membuat sistem menjadi lebih kompleks dan lebih bermanfaat dalam penerapan nyata. Selain itu, model dapat dilatih menggunakan dataset dengan kondisi pencahayaan yang lebih beragam.

Sistem juga dapat dikembangkan menjadi aplikasi berbasis web atau perangkat mobile. Pengguna nantinya dapat melakukan klasifikasi secara langsung melalui kamera atau unggahan gambar. Dengan pengembangan tersebut, hasil penelitian dapat dimanfaatkan secara lebih luas dan praktis.